



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

# 第4章 逐次逼近法

## 4.3 计算特征值的幂法



在很多工程技术和科学计算中，经常会碰到计算矩阵的特征问题。设  $A \in \mathbf{R}^{n \times n}$ ，矩阵  $A$  的特征问题是求数  $\lambda$  和非零向量  $\mathbf{x}$ ，使得

$$A\mathbf{x} = \lambda\mathbf{x}, \quad (4-32)$$

在线性代数中曾经计算过低阶矩阵的特征问题，即由  $n$  次代数方程

$$f(\lambda) = \det(\lambda\mathbf{I} - A) = 0 \quad (4-33)$$

中，求出 (4-33) 的根  $\lambda_i$ ，即为  $A$  的特征值，再从线性方程组

$$(\lambda_i\mathbf{I} - A)\mathbf{x} = \mathbf{0} \quad (4-34)$$

中求出  $\mathbf{x}^{(i)}$ ，即为  $\lambda_i$  的关于的特征向量  $\mathbf{x}^{(i)}$ 。 $\lambda_i$  和  $\mathbf{x}^{(i)}$  称为  $A$  的特征对。

### 4.3.1 幂法

用解非线性方程和解线性方程组的方法求矩阵特征问题, 一般情况计算量很大。因此, 须考虑用其他方法计算A的特征对。在不少工程实际中往往需要求矩阵A绝对值(模)最大或最小的特征值。**幂法**就是求这种特征值与相应的特征向量的方法。

矩阵A绝对值最大的特征值称**主特征值**。 设A的特征值和对应的特征向量分别为

$$\lambda_1, \lambda_2, \dots, \lambda_n \quad \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$$

且 $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$ ;  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$  构成A的线性无关特征向量组。 则对任一n维向量 $\mathbf{v}^{(0)}$ 均可表示成

和 
$$\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{x}^{(n)} \quad (\alpha_1 \neq 0)$$

$$\mathbf{A}\mathbf{v}^{(0)} = \alpha_1 \mathbf{A}\mathbf{x}^{(1)} + \alpha_2 \mathbf{A}\mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{A}\mathbf{x}^{(n)}$$

$$\begin{aligned}\mathbf{A}\mathbf{v}^{(0)} &= \alpha_1\mathbf{A}\mathbf{x}^{(1)} + \alpha_2\mathbf{A}\mathbf{x}^{(2)} + \cdots + \alpha_n\mathbf{A}\mathbf{x}^{(n)} \\ &= \alpha_1\lambda_1\mathbf{x}^{(1)} + \alpha_2\lambda_2\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n\mathbf{x}^{(n)}\end{aligned}$$

$$\mathbf{A}^2\mathbf{v}^{(0)} = \alpha_1\lambda_1^2\mathbf{x}^{(1)} + \alpha_2\lambda_2^2\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n^2\mathbf{x}^{(n)}$$

$$\vdots$$

$$\mathbf{A}^k\mathbf{v}^{(0)} = \alpha_1\lambda_1^k\mathbf{x}^{(1)} + \alpha_2\lambda_2^k\mathbf{x}^{(2)} + \cdots + \alpha_n\lambda_n^k\mathbf{x}^{(n)}$$

$$= \lambda_1^k \cdot \left[ \alpha_1\mathbf{x}^{(1)} + \alpha_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{x}^{(2)} + \cdots + \alpha_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{x}^{(n)} \right]$$

则 
$$\frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1\mathbf{x}^{(1)} + \alpha_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{x}^{(2)} + \cdots + \alpha_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{x}^{(n)}$$

因为  $\left|\frac{\lambda_i}{\lambda_1}\right| < 1, (i=2, 3, \cdots, n)$ , 所以

$$\lim_{k \rightarrow \infty} \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1\mathbf{x}^{(1)}$$

(4-35)



(4-35)说明  $\frac{A^k \mathbf{v}^{(0)}}{\lambda_1^k}$  随着的 $k$ 无限增大, 趋于 $A$ 的主特征值对应的特征向量 $\mathbf{x}^{(1)}$  (特征向量乘一个不为0的常数  $\alpha$  特征向量后, 仍为原特征值对应的特征向量)。

若令  $\mathbf{v}^{(k)} = A^k \mathbf{v}^{(0)}$ , 则  $\mathbf{v}^{(k)} \approx \lambda_1^k \alpha_1 \mathbf{x}^{(1)} = (\alpha_1 \lambda_1^k) \mathbf{x}^{(1)}$

故 $\mathbf{v}^{(k)}$ 也可作为 $\lambda_1$ 对应的近似特征向量。 又因为

$$\frac{v_i^{(k)}}{v_i^{(k-1)}} = \frac{(A^k \mathbf{v}^{(0)})_i}{(A^{k-1} \mathbf{v}^{(0)})_i} = \frac{\left[ \lambda_1^k \left( \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right) \right]_i}{\left[ \lambda_1^{k-1} \left( \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right) \right]_i}$$

$$= \lambda_1 \frac{\left[ \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]_i}{\left[ \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]_i}$$

其中  $\mathbf{v}^{(k)} = (v_1^{(k)}, v_2^{(k)}, \dots, v_n^{(k)})^T$ 。所以

$$\lim_{k \rightarrow \infty} \frac{v_i^{(k)}}{v_i^{(k-1)}} = \lambda_1 \quad (4-36)$$

(4-36) 表明，序列  $\frac{v_i^{(k)}}{v_i^{(k-1)}} (k=1, 2, \dots)$  收敛于A的主特征值  $\lambda_1$ ，其收敛速度取决于比值  $r = \left| \frac{\lambda_2}{\lambda_1} \right|$  的大小， $r$  越小，收敛速度越快，

如果  $r \approx 1$ ，则收敛速度就很慢，需要采用加速技术。

综上所述，可得如下定理

**定理4.8** 若矩阵A具有n个线性无关的特征向量

$$\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$$

且对应的特征值满足  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$ , 则取  $\mathbf{v}^{(0)} \neq 0$ , 经使用

$$\mathbf{v}^{(k)} = \mathbf{A}^k \mathbf{v}^{(0)} \quad k = 1, 2, \dots \quad (4-37)$$

迭代计算可得

$$1) \quad \mathbf{v}^{(k)} = \alpha_1 \lambda_1^k \mathbf{x}^{(1)} \quad (\alpha_1 \neq 0) \quad (4-38)$$

$$2) \quad \frac{v_i^{(k)}}{v_i^{(k-1)}} \approx \lambda_1 \quad (4-39)$$

利用 (4-37)、(4-38)、(4-39) 计算A的主特征值  $\lambda_1$ , 及其对应的特征向量  $\mathbf{x}^{(1)}$  的方法, 称为**幂法**。其中  $(\lambda_1, \mathbf{x}^{(1)})$  也称**极端特征对**。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

在使用幂法法时还应注意:

1) 由于在取初始向量 $\mathbf{v}^{(k)}$ 时,  $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}$  事先不知, 可能使  $\mathbf{v}^{(0)} = \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \dots + \alpha_n \mathbf{x}^{(n)}$  中的  $\alpha_1 = 0$ 。从理论上讲, 此时必须换初始向量 $\mathbf{v}^{(0)}$ , 否则算不出 $\mathbf{x}^{(1)}$ , 但是在实际计算时, 由于舍入误差的影响, 可能经几步迭代后得到

$$\mathbf{v}^{(t)} = \mathbf{A}^t \mathbf{v}^{(0)} = \beta_1 \mathbf{x}^{(1)} + \beta_2 \mathbf{x}^{(2)} + \dots + \beta_n \mathbf{x}^{(n)}$$

其中  $\beta_1 \neq 0$ , 这样继续算下去仍可算出 $\mathbf{x}^{(1)}$ 的近似值, 但是迭代次数就要增加, 如果发现收敛速度很慢, 可以更换初始向量 $\mathbf{v}^{(0)}$ 后再进行迭代计算。



2) 从(4-38)中易知, 当 $|\lambda_1| > 1$  (或 $|\lambda_1| < 1$ ) 时, 数值计算将产生“溢出”, 即计算 $\mathbf{v}^{(k)}$ , 当 $k \rightarrow \infty$ 时,  $\mathbf{v}^{(k)}$ 中的非零分量将趋于零或无穷大。为了避免这种现象的产生, 需要将由(4-38)式每次算得的向量 $\mathbf{v}$ 进行规范化, 即在向量上除以一个常数。

为了方便起见, 除数可取该向量绝对值最大的分量, 并记为 $\max(\mathbf{v})$ 。

若  $\mathbf{v} = (v_1, v_2, \dots, v_n)^T$  且  $|v_k| = \max_{1 \leq i \leq n} |v_i|$

则  $\max(\mathbf{v}) = v_k$

令 
$$\mathbf{u} = \frac{\mathbf{v}}{\max(\mathbf{v})} = \left( \frac{v_1}{v_k}, \frac{v_2}{v_k}, \dots, \frac{v_n}{v_k} \right)^T$$

如此规范后的向量 $\mathbf{v}$ , 其绝对值最大的分量的值为1。

于是幂法可作如下表达:

(1) 取初始向量  $\mathbf{v}^{(0)} \neq \mathbf{0}$ , 且  $\alpha_1 \neq 0$ , 并令  $\mathbf{u}^{(0)} = \mathbf{v}^{(0)}$

$$(2) \quad \mathbf{v}^{(1)} = \mathbf{A}\mathbf{v}^{(0)} = \mathbf{A}\mathbf{u}^{(0)}$$

$$\mathbf{u}^{(1)} = \frac{\mathbf{v}^{(1)}}{\max(\mathbf{v}^{(1)})} = \frac{\mathbf{A}\mathbf{v}^{(0)}}{\max(\mathbf{A}\mathbf{v}^{(0)})}$$

$$(3) \quad \mathbf{v}^{(2)} = \mathbf{A}\mathbf{u}^{(1)} = \frac{\mathbf{A}^2\mathbf{v}^{(0)}}{\max(\mathbf{A}\mathbf{v}^{(0)})} = \frac{\mathbf{A}\mathbf{v}^{(1)}}{\max(\mathbf{A}\mathbf{v}^{(0)})}$$

$$\mathbf{u}^{(2)} = \frac{\mathbf{v}^{(2)}}{\max(\mathbf{v}^{(2)})} = \frac{\mathbf{A}^2\mathbf{v}^{(0)}}{\max(\mathbf{A}^2\mathbf{v}^{(0)})}$$

$$(4) \quad \begin{cases} \mathbf{v}^{(k)} = \mathbf{A}\mathbf{u}^{(k-1)} = \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1}\mathbf{v}^{(0)})} \\ \mathbf{u}^{(k)} = \frac{\mathbf{v}^{(k)}}{\max(\mathbf{v}^{(k)})} = \frac{\mathbf{A}^k\mathbf{v}^{(0)}}{\max(\mathbf{A}^k\mathbf{v}^{(0)})} \\ k = 3, 4, \dots \end{cases} \quad (4-40)$$

因为

$$\begin{aligned}\mathbf{u}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^k \mathbf{v}^{(0)})} = \frac{\lambda_1^k \left[ \alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left( \lambda_1^k \left[ \alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right] \right)} \\ &= \frac{\left[ \alpha_1 \mathbf{x}^{(1)} + \alpha_n \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left( \alpha_1 \mathbf{x}^{(1)} + \alpha_n \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right)}\end{aligned}$$

所以

$$\lim_{k \rightarrow \infty} \mathbf{u}^{(k)} = \frac{\alpha_1 \mathbf{x}^{(1)}}{\max(\alpha_1 \mathbf{x}^{(1)})} = \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})}$$

又因为

$$\begin{aligned}\mathbf{v}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1} \mathbf{v}^{(0)})} = \frac{\lambda_1^k \left[ \alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\lambda_1^{k-1} \max \left[ \alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]} \\ &= \lambda_1 \frac{\left[ \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right]}{\max \left[ \alpha_1 \mathbf{x}^{(1)} + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k-1} \mathbf{x}^{(2)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k-1} \mathbf{x}^{(n)} \right]}\end{aligned}$$

所以

$$\lim_{k \rightarrow \infty} \max(\mathbf{v}^{(k)}) = \lambda_1$$

故当 $k$ 足够大时

$$\mathbf{u}^{(k)} \approx \frac{\mathbf{x}^{(1)}}{\max(\mathbf{x}^{(1)})} \quad (4-41)$$

即 $\mathbf{u}^{(k)}$ 为主特征值对应的特征向量的近似向量。

$$\max(\mathbf{v}^{(k)}) \approx \lambda_1 \quad (4-42)$$

$\max(\mathbf{v}^{(k)})$ 为主特征值的近似值。

例1 用幂法计算矩阵  $A = \begin{pmatrix} 1.0 & 1.0 & 0.5 \\ 1.0 & 1.0 & 0.25 \\ 0.5 & 0.25 & 2.0 \end{pmatrix}$  的极端特征对，

取  $\mathbf{v}^{(0)} = (1, 1, 1)^T$ 。结果见下表

$k$	$(\mathbf{u}^{(k)})^T$ (规范化向量)	$\max(\mathbf{v}^{(k)})$
1	(0.9091, 0.8182, 1)	2.750000
$\vdots$	$\vdots$	$\vdots$
5	(0.7651, 0.6674, 1)	2.558792
$\vdots$	$\vdots$	$\vdots$
10	(0.7494, 0.6508, 1)	2.538003
$\vdots$	$\vdots$	$\vdots$
15	(0.7483, 0.6497, 1)	2.536626
16	(0.7483, 0.6497, 1)	2.536584
17	(0.7483, 0.6497, 1)	2.536560
18	(0.7483, 0.6497, 1)	2.536546
19	(0.7483, 0.6497, 1)	2.536537
20	(0.7483, 0.6497, 1)	2.536532

主特征值的计算值为：

$$\lambda_1 \approx 2.536532$$

$\lambda_1$  对应的特征向量为：

$$\mathbf{x}^{(1)} \approx (0.7482, 0.6497, 1)^T$$



如果矩阵A的特征值不满足假设

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_n|$$

此时幂法的收敛性分析就变得复杂，它可能产生如下几种情况

(1)  $\lambda_1 = \lambda_2 = \cdots = \lambda_r$  , 且  $|\lambda_1| > |\lambda_{r+1}|$

(2)  $\lambda_1 = \lambda_2 = \cdots = \lambda_t$  ,  $\lambda_{t+1} = \lambda_{t+2} = \cdots = \lambda_r = -\lambda_1$

且  $|\lambda_1| > |\lambda_{r+1}|$

(3)  $\lambda_1 = \bar{\lambda}_2$  , 且  $|\lambda_1| > |\lambda_3|$

对于情况 (1) , 由于

$$\begin{aligned}
 \mathbf{A}^k \mathbf{v}^{(0)} &= \alpha_1 \lambda_1^k \mathbf{x}^{(1)} + \cdots + \alpha_r \lambda_1^k \mathbf{x}^{(r)} + \alpha_{r+1} \lambda_{r+1}^k \mathbf{x}^{(r+1)} + \cdots + \alpha_n \lambda_n^k \mathbf{x}^{(n)} \\
 &= \lambda_1^k \left[ \left( \alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_r \mathbf{x}^{(r)} \right) + \alpha_{r+1} \left( \frac{\lambda_{r+1}}{\lambda_1} \right)^k \mathbf{x}^{(r+1)} + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}^{(n)} \right] \\
 \mathbf{u}^{(k)} &= \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^k \mathbf{v}^{(0)})} \rightarrow \frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \cdots + \alpha_r \mathbf{x}^{(r)})}, \quad \text{当 } k \rightarrow \infty \text{ 时。}
 \end{aligned}$$

$$\mathbf{v}^{(k)} = \frac{\mathbf{A}^k \mathbf{v}^{(0)}}{\max(\mathbf{A}^{k-1} \mathbf{v}^{(0)})} \rightarrow \lambda_1 \frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} \cdots + \alpha_r \mathbf{x}^{(r)})}$$

则当  $k \rightarrow \infty$  时,  $\max(\mathbf{v}^{(k)}) \rightarrow \lambda_1$ 。

故在情况 (1), 若  $\mathbf{v}^{(0)}$  的展开式中, 如果  $\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)} \neq 0$

则矩阵  $\mathbf{A}$  的主特征值近似于  $\max(\mathbf{v}^{(k)})$ , 对应的近似特征向量为

$$\frac{\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} + \cdots + \alpha_r \mathbf{x}^{(r)}}{\max(\alpha_1 \mathbf{x}^{(1)} + \alpha_2 \mathbf{x}^{(2)} \cdots + \alpha_r \mathbf{x}^{(r)})}$$

情况 (2) 和 (3) 的分析较 (1) 要复杂, 读者可以参看 [5] 的第二章。



**DUT**

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

THE END