



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

第4章 逐次逼近法

4.5 共轭梯度法

4.5 共轭梯度法

SOR迭代法是解大型稀疏线性方程组的有效方法，但是需选取适用的松弛因子。出现在20世纪50年代的共轭梯度法是解大型稀疏线性方程组的理想方法之一。经过适当改进还可用于解病态线性方程组。在介绍本方法前，首先需将线性方程组进行等价变形。

设线性方程组：

$$Ax = b \quad (4-62)$$

其中 A 为 n 阶对称正定矩阵， $b \in \mathbf{R}^n$ ， $x \in \mathbf{R}^n$ 为待求向量。

考察二次函数 $\varphi(x): \mathbf{R}^n \rightarrow \mathbf{R}$

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2} \sum_{j=1}^n \left(\sum_{i=1}^n a_{ij} x_i \right) x_j - \sum_{j=1}^n b_j x_j$$

则有

定理4.9 x^* 是 $Ax=b$ 解 (A 为对称正定矩阵) 的充分必要条件

为 x^* 满足

$$\varphi(x^*) = \min_{x \in \mathbf{R}^n} \varphi(x)$$

证 必要性 设 $Ax=b$, 取 $x=x^*+tp$, 其中 $t \in \mathbf{R}, 0 \neq p \in \mathbf{R}^n$, 则

$$\begin{aligned}\varphi(x^* + tp) &= \frac{1}{2} (A(x^* + tp), x^* + tp) - (b, x^* + tp) \quad \text{注意到 } A=A^T, \\&= \frac{1}{2} (Ax^*, x^*) + \frac{t}{2} (Ax^*, p) + \frac{t}{2} (Ap, x^*) + \frac{t^2}{2} (Ap, p) - (b, x^*) - t(b, p) \\&= \frac{1}{2} (Ax^*, x^*) - (b, x^*) + \frac{t}{2} [(Ax^*, p) + (Ap, x^*) - 2(b, p)] + \frac{t^2}{2} (Ap, p) \\&= \varphi(x^*) + t(Ax^* - b, p) + \frac{t^2}{2} (Ap, p) \\&= \varphi(x^*) + \frac{t^2}{2} (Ap, p)\end{aligned}$$

因为 A 为正定矩阵, 所以 $\frac{t^2}{2} (Ap, p) \geq 0$, 故

$$\varphi(x^* + tp) \geq \varphi(x^*)$$

即 x^* 使 $\varphi(x)$ 达到最小。

$$\varphi(\mathbf{x}^* + t\mathbf{p}) = \varphi(\mathbf{x}^*) + t(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) + \frac{t^2}{2}(\mathbf{Ap}, \mathbf{p})$$

充分性 设 $\varphi(\mathbf{x}^*) = \min_{\mathbf{x} \in \mathbf{R}^n} \varphi(\mathbf{x})$, 则应有 $\varphi(\mathbf{x}^* + t\mathbf{p})$ 于 $t=0$ 取极小值, 也即 $\forall \mathbf{p} \in \mathbf{R}^n$

$$\left[\varphi'(\mathbf{x}^* + t\mathbf{p}) \right] \Big|_{t=0} = \left[(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) + t(\mathbf{Ap}, \mathbf{p}) \right] \Big|_{t=0} = (\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) = 0$$

从而 $(\mathbf{Ax}^* - \mathbf{b}, \mathbf{p}) = 0 \Leftrightarrow \mathbf{x}^*$ 是 $\mathbf{Ax} = \mathbf{b}$ 的解。

又由 $\varphi(\mathbf{x}^* + t\mathbf{p})$ 于 $t=0$ 取极小值的充分条件, 即得

$$(\mathbf{Ap}, \mathbf{p}) = \varphi''(0) > 0 \quad \forall \mathbf{p} \in \mathbf{R}^n \quad \text{故} \mathbf{A} \text{ 必为正定矩阵。}$$

定理4.9说明, 求 $\mathbf{Ax} = \mathbf{b}$ 的解的问题等价于求 $\varphi(\mathbf{x})$ 的最小值问题。
在介绍共轭梯度法前, 先介绍较为直观的最速下降法。

4.5.1 最速下降法

取初始向量 \mathbf{x}_0 ，从 \mathbf{x}_0 出发构造向量序列 $\{\mathbf{x}_k\}$ 使 $\varphi(\mathbf{x}_{k-1}) > \varphi(\mathbf{x}_k)$

构造方法：选取方向 \mathbf{x}_0 ，使 $\varphi(\mathbf{x})$ 在 \mathbf{x}_0 处沿 \mathbf{y}_0 方向减小的速度最快。

据多元函数场论可知， \mathbf{y}_0 应为 $\varphi(\mathbf{x})$ 的负梯度方向，即

$$\mathbf{y}_0 = -\nabla \varphi(\mathbf{x}_0) = \mathbf{r}_0 = \mathbf{b} - \mathbf{A}\mathbf{x}_0 \quad \varphi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{x}^T \mathbf{b}$$

再在方向 \mathbf{r}_0 上进行一维极小搜索，即在 $\mathbf{x}_0 + \alpha \mathbf{r}_0$ 中选取 α_0 使得 $\varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)$ 极小，即求 $\min_{\alpha \in R} \varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)$

$$\begin{aligned} \frac{d\varphi(\mathbf{x}_0 + \alpha \mathbf{r}_0)}{d\alpha} &= \frac{d}{d\alpha} \left[\varphi(\mathbf{x}_0) + \alpha (\mathbf{A}\mathbf{x}_0 - \mathbf{b}, \mathbf{r}_0) + \frac{\alpha^2}{2} (\mathbf{A}\mathbf{r}_0, \mathbf{r}_0) \right] \\ &= -(\mathbf{r}_0, \mathbf{r}_0) + \alpha (\mathbf{A}\mathbf{r}_0, \mathbf{r}_0) = 0 \end{aligned}$$

则 $\alpha = \alpha_0 = \frac{(\mathbf{r}_0, \mathbf{r}_0)}{(\mathbf{A}\mathbf{r}_0, \mathbf{r}_0)}$, 由于 $\frac{d^2}{d\alpha^2} \varphi(\mathbf{x}_0 + \alpha\mathbf{r}_0) = (\mathbf{A}\mathbf{r}_0, \mathbf{r}_0) > 0$

故 $\min_{\alpha \in R} \varphi(\mathbf{x}_0 + \alpha\mathbf{r}_0) = \varphi(\mathbf{x}_0 + \alpha\mathbf{r}_0)$

令 $\mathbf{x}_1 = \mathbf{x}_0 + \alpha\mathbf{r}_0$, 重复上面的过程, 可得

$$\begin{cases} \mathbf{r}_k = \mathbf{b} - \mathbf{A}\mathbf{x}_k \\ \alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)} \\ \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k \end{cases} \quad (4-63)$$

由于 $\varphi(\mathbf{x}_0) > \varphi(\mathbf{x}_1) > \cdots > \varphi(\mathbf{x}_k) > \cdots \geq \varphi(\mathbf{x}^*)$, $\{\varphi(\mathbf{x}_k)\}$ 存在极限,

而且

$$\lim_{k \rightarrow \infty} \mathbf{x}_k = \mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}$$

$$(1) \quad (\mathbf{r}_{k+1}, \mathbf{r}_k) = 0 \quad k = 0, 1, 2, \dots \quad (4-64)$$

还可以证明


$$(2) \quad \|\mathbf{x}_k - \mathbf{x}^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|_A \quad (4-65)$$

其中 λ_1, λ_n 分别为 \mathbf{A} 的模最大和最小特征值, $\|\mathbf{x}\|_A = (\mathbf{A}\mathbf{x}, \mathbf{x})^{\frac{1}{2}}$ 。

最速下降的几何意义

取定初始值 $\mathbf{x}^{(0)}$ ，于超椭圆 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(0)})$ 上过 $\mathbf{x}^{(0)}$ ，作其内法线 $\mathbf{r}^{(0)}$ ，它就是 $\varphi(\mathbf{x})$ 在 $\mathbf{x}^{(0)}$ 点的最速下降方向，然后在射线 $\mathbf{x}^{(0)} + \alpha \mathbf{r}^{(0)}$ 上求与 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(0)})$ 的另一交点 $\bar{\mathbf{x}}^{(0)}$ ， $\bar{\mathbf{x}}^{(0)}$ ， $\mathbf{x}^{(0)}$ 的中点即为 $\mathbf{x}^{(1)}$ ，它也是 $\mathbf{x}^{(0)} - \alpha \mathbf{r}^{(0)}$ 与 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(1)})$ 的切点。

过 $\mathbf{x}^{(1)}$ 再作 $\varphi(\mathbf{x}) = \varphi(\mathbf{x}^{(1)})$ 的内法线 $\mathbf{r}^{(1)}$ ，然后沿着此方向求 $\bar{\mathbf{x}}^{(1)}$ ， $\mathbf{x}^{(2)}$ ，等等 \cdots ，如此继续下去就得到最速下降的迭代序列。



$$\text{验证 } (\mathbf{r}_{k+1}, \mathbf{r}_k) = 0 \quad k = 0, 1, 2, \dots \quad (4-64)$$

$$\text{由 } \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k$$

$$\text{得 } \mathbf{r}_{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}_{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}_k + \alpha_k \mathbf{r}_k) = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{r}_k$$

$$\text{从而 } (\mathbf{r}_{k+1}, \mathbf{r}_k) = (\mathbf{r}_k, \mathbf{r}_k) - \alpha_k (\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)$$

$$\begin{aligned} \alpha_k &= \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)} = (\mathbf{r}_k, \mathbf{r}_k) - \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{r}_k, \mathbf{r}_k)} (\mathbf{A}\mathbf{r}_k, \mathbf{r}_k) \\ &= (\mathbf{r}_k, \mathbf{r}_k) - (\mathbf{r}_k, \mathbf{r}_k) \end{aligned}$$

$$0$$

当 λ_1 与 λ_n 相差很大时, 据 (4-65) 可知, $\{\mathbf{x}_k\}$ 收敛很慢, 而且当 $\|\mathbf{r}_k\|$ 很小时, 由于舍入误差的影响, 由 (4-63) 的计算将出现不稳定现象, 所以在实际计算中很少使用最速下降法。

4.5.2 共轭梯度法 (简称CG法)

从 (4-65) 可以看出, 我们采用一维搜索所沿的方向 $\mathbf{r}_0, \mathbf{r}_1, \dots, \mathbf{r}_k, \dots$ 可能使的收敛速度缓慢, 因此, 我们需要另找一组方向 $\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_k, \dots$ 进行一维极小搜索。设按方向 $\mathbf{p}_0, \mathbf{p}_1, \dots, \mathbf{p}_{k-1}$ 已经进行 k 次一维搜索, 已求出 \mathbf{x}_k , 下一步确定进行求解极小问题

$$\min \varphi(\mathbf{x}_k + \alpha \mathbf{p}_k)$$

与4.5.1中的方法一样, 令

$$\frac{d\varphi(\mathbf{x}_k + \alpha \mathbf{p}_k)}{d\alpha} = 0$$



解得

$$\alpha = \alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (4-66)$$

从而得到下一个近似解和对应的余向量

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k \quad (4-67)$$

$$\begin{aligned} \mathbf{r}_{k+1} &= \mathbf{b} - \mathbf{A}\mathbf{x}_{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}_k + \alpha_k \mathbf{p}_k) \\ &= \mathbf{b} - \mathbf{A}\mathbf{x}_k - \alpha_k \mathbf{A}\mathbf{p}_k = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k \end{aligned} \quad (4-68)$$

反复利用 (4-67)，可得

$$\begin{aligned} \mathbf{x}_{k+1} &= \mathbf{x}_k + \alpha_k \mathbf{p}_k = \mathbf{x}_{k-1} + \alpha_{k-1} \mathbf{p}_{k-1} + \alpha_k \mathbf{p}_k \\ &\quad \dots \dots \dots \\ \mathbf{x}_{k+1} &= \mathbf{x}_0 + \alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \dots + \alpha_k \mathbf{p}_k \end{aligned}$$

为讨论方便，又不失一般性，可以令 $\mathbf{x}_0 = \mathbf{0}$ 。

下面讨论 $p_0, p_1, \cdots, p_k \cdots$ 的取法。

开始时 $p_0=r_0$ 取, 如果 $k \geq 1$ 时, p_k 的确定希望满足

$$(1) \quad \varphi(x_{k+1}) = \min_{\alpha} \varphi(x_k + \alpha p_k)$$

其中 α 与 x_{k+1} 由 (4-66)、(4-67) 确定。

$$(2) \quad \varphi(x_{k+1}) = \min_{x \in R^{k+1}} \varphi(x)$$

其中 $R^{k+1} = \text{span}\{p_0, p_1, \cdots, p_k\}$

若 $x \in R^{k+1}$ 时, x 可以写成 $x = y + \alpha p_k$,

$$y \in \text{span}\{p_0, p_1, \cdots, p_{k-1}\} = R^k$$

故有

$$\varphi(x) = \varphi(y + \alpha p_k)$$

$$= \varphi(y) + \alpha(Ay, p_k) - \alpha(b, p_k) + \frac{\alpha^2}{2}(Ap_k, p_k) \quad (4-69)$$

$$\varphi(\mathbf{x}) = \varphi(\mathbf{y} + \alpha \mathbf{p}_k) = \varphi(\mathbf{y}) + \alpha(\mathbf{A}\mathbf{y}, \mathbf{p}_k) - \alpha(\mathbf{b}, \mathbf{p}_k) + \frac{\alpha^2}{2}(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)$$

为了能在 (4-69) 中分别对 \mathbf{y} 和 α 求极小, 可以令 $(\mathbf{A}\mathbf{y}, \mathbf{p}_k) = 0$, 其中 $\mathbf{y} \in \mathbf{R}^k$, 即

$$\mathbf{y} = \alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \cdots + \alpha_{k-1} \mathbf{p}_{k-1}, \quad (\alpha_0, \cdots, \alpha_{k-1})^T \neq (0, \cdots, 0)^T$$

故由 $(\mathbf{A}\mathbf{y}, \mathbf{p}_k) = 0$, 立刻可以推出

$$(\mathbf{A}\mathbf{p}_j, \mathbf{p}_k) = 0, \quad j = 0, 1, \cdots, k-1 \quad (4-70)$$

定义4.3 若 \mathbf{A} 为对称正定阵, 如果向量组 $\mathbf{p}_0, \mathbf{p}_1, \cdots, \mathbf{p}_k$ 满足

$$(\mathbf{A}\mathbf{p}_i, \mathbf{p}_j) = 0 \quad i \neq j$$

则称该向量组为 **A-正交向量组** 或称 **A-共轭向量组**。

若 $\mathbf{A} = \mathbf{I}$ (单位阵), 则 $\mathbf{p}_0, \mathbf{p}_1, \cdots, \mathbf{p}_k$ 就是普通的正交向量组。

现在求极小问题 (4-69) 的解, 若取 $\{\mathbf{p}_i\}$ 为 \mathbf{A} -共轭向量组,

\mathbf{x}_k 已为前一步极小问题的解, 则

$$\min_{\mathbf{x} \in \mathbf{R}^{k+1}} \varphi(\mathbf{x}) = \min_{\mathbf{y}, \alpha} \varphi(\mathbf{y} + \alpha \mathbf{p}_k) = \min_{\mathbf{y}} \varphi(\mathbf{y}) + \min_{\alpha} \left[\frac{\alpha^2}{2}(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) - \alpha(\mathbf{b}, \mathbf{p}_k) \right]$$

(1) $\min_y \varphi(\mathbf{y})$ 的解, 由于 $\mathbf{y} \in \mathbf{R}^k$, 其解已在前一步求得, 即

(2) $\min_{\alpha} \left[\frac{\alpha^2}{2} (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) - \alpha(\mathbf{b}, \mathbf{p}_k) \right]$ 的解。 其解为

$$\alpha = \alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad \alpha = \alpha_k = \frac{(\mathbf{b}, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \quad (4-71)$$

因为 $\mathbf{x}_k \in \mathbf{R}^k$, 所以 $\mathbf{x}_k = \alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \cdots + \alpha_{k-1} \mathbf{p}_{k-1}$, 故

$$\mathbf{A}\mathbf{x}_k = \alpha_0 \mathbf{A}\mathbf{p}_0 + \alpha_1 \mathbf{A}\mathbf{p}_1 + \cdots + \alpha_{k-1} \mathbf{A}\mathbf{p}_{k-1}$$

从而有

$$(\mathbf{A}\mathbf{x}_k, \mathbf{p}_k) = \alpha_0 (\mathbf{A}\mathbf{p}_0, \mathbf{p}_k) + \alpha_1 (\mathbf{A}\mathbf{p}_1, \mathbf{p}_k) + \cdots + \alpha_{k-1} (\mathbf{A}\mathbf{p}_{k-1}, \mathbf{p}_k) = 0$$

这样就有

$$\underline{(\mathbf{b}, \mathbf{p}_k)} = (\mathbf{b}, \mathbf{p}_k) - (\mathbf{A}\mathbf{x}_k, \mathbf{p}_k) = (\mathbf{b} - \mathbf{A}\mathbf{x}_k, \mathbf{p}_k) = \underline{(\mathbf{r}_k, \mathbf{p}_k)}$$

故 (4-66) 与 (4-71) 是相同的。

现在给出CG中的一种求法。

设 $r_0=p_0, p_1, \dots, p_{k-1}$ 已求出, 现在要求 p_k , 由于 p_k 不唯一, 所以可取一种简单方法来确定 p_k , 设

$$p_k = r_k + \beta_{k-1} p_{k-1} \quad (4-72)$$

则 $0 = (p_k, Ap_{k-1}) = (r_k, Ap_{k-1}) + \beta_{k-1} (p_{k-1}, Ap_{k-1})$

$$\beta_{k-1} = -\frac{(r_k, Ap_{k-1})}{(p_{k-1}, Ap_{k-1})} \quad (4-73)$$

由(4-72)、(4-73)得到的 p_k , 还可用于简化 α_k 的计算。

因为由(4-68)与(4-66)有

$$\begin{aligned} (r_{k+1}, p_k) &= (r_k - \alpha_k Ap_k, p_k) = (r_k, p_k) - \alpha_k (Ap_k, p_k) \\ &= (r_k, p_k) - \frac{(r_k, p_k)}{(Ap_k, p_k)} (Ap_k, p_k) = 0 \end{aligned}$$

$$\begin{aligned}
 (\mathbf{r}_k, \mathbf{p}_k) &= (\mathbf{r}_k, \mathbf{r}_k + \beta_{k-1} \mathbf{p}_{k-1}) = (\mathbf{r}_k, \mathbf{r}_k) + \beta_{k-1} (\mathbf{r}_k, \mathbf{p}_{k-1}) \\
 &= (\mathbf{r}_k, \mathbf{r}_k)
 \end{aligned} \tag{4-74}$$

故有

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \tag{4-75}$$

当 $\mathbf{r}_k \neq \mathbf{0}$ 时, $\alpha_k > 0$ 。

用前面的已有公式, 还可以证明:

$$(1) \quad (\mathbf{r}_i, \mathbf{r}_j) = 0 \quad (i \neq j) \tag{4-76}$$

$$(2) \quad (\mathbf{A}\mathbf{p}_i, \mathbf{p}_j) = (\mathbf{p}_i, \mathbf{A}\mathbf{p}_j) = 0 \quad (i \neq j) \tag{4-77}$$

即 $\mathbf{r}_0, \mathbf{r}_1, \cdots$ 构成正交向量组, $\mathbf{p}_0, \mathbf{p}_1, \cdots$ 构成 \mathbf{A} -正交向量组。



利用 (4-68) 和 (4-76) 还可简化 β_k 的计算,

$$\begin{aligned}\beta_k &= -\frac{(\mathbf{r}_{k+1}, A\mathbf{p}_k)}{(\mathbf{p}_k, A\mathbf{p}_k)} = -\frac{(\mathbf{r}_{k+1}, \alpha_k^{-1}(\mathbf{r}_k - \mathbf{r}_{k+1}))}{(\mathbf{p}_k, A\mathbf{p}_k)} \\ &= -\frac{\alpha_k^{-1}(\mathbf{r}_{k+1}, \mathbf{r}_k)}{(\mathbf{p}_k, A\mathbf{p}_k)} + \frac{\alpha_k^{-1}(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{p}_k, A\mathbf{p}_k)} \\ &= \frac{(A\mathbf{p}_k, \mathbf{p}_k)}{(\mathbf{r}_k, \mathbf{r}_k)} \cdot \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(A\mathbf{p}_k, \mathbf{p}_k)} = \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{r}_k, \mathbf{r}_k)}\end{aligned}\quad (4-78)$$

当 $\mathbf{r}_{k+1} \neq 0$ 时, $\beta_k > 0$ 。

共轭梯度法（CG法）：

(1) 任取 $\mathbf{x}_0 \in \mathbf{R}^n$

(2) $\mathbf{r}_0 = \mathbf{b} - \mathbf{A}\mathbf{x}_0$ ，取 $\mathbf{p}_0 = \mathbf{r}_0$

(3) 对 $k=1, 2, \dots$

$$\alpha_k = \frac{(\mathbf{r}_k, \mathbf{r}_k)}{(\mathbf{p}_k, \mathbf{A}\mathbf{p}_k)}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{A}\mathbf{p}_k$$

$$\beta_k = \frac{(\mathbf{r}_{k+1}, \mathbf{r}_{k+1})}{(\mathbf{r}_k, \mathbf{r}_k)}$$

$$\mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k$$

在计算过程中若有 $\mathbf{r}_k = \mathbf{0}$ 或 $(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = 0$ 时计算终止，即有 $\mathbf{x}_k = \mathbf{x}^*$ 。



当 $(Ap_k, p_k)=0$ 时, 由于 A 为正定阵, 必有 $p_k=0$, 则由(4-74)有

$$(r_k, r_k) = (r_k, p_k) = 0$$

即 $r_k = b - Ax_k = 0$ 。

由于 n 维空间中正交向量组的向量个数最多只有 n 个, 所以 r_0, r_1, \dots, r_n 中至少有一个为零向量, 若 $r_j=0$, 则 $r_j=x^*$ 。所以使用CG法求解 n 阶线性方程组, 理论上最多 n 步便可得到精确解, 因此, 也可称为直接法。但是, 由于舍入误差的影响, $\{r_k\}$ 的正交性很难达到, 所以在实际计算时往往不能在 n 步得到精确解, 因此, 通常将CG法还是作为逐次逼近法使用。

例1 用CG法解线性方程组

$$\begin{pmatrix} 2 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

解 显然方程组的系数阵为对称正定阵，取 $\mathbf{x}_0 = (0,0,0)^T$

$$\mathbf{r}_0 = \mathbf{b} - \mathbf{A}\mathbf{x}_0 = \mathbf{p}_0 = (1, 1, 1)^T, \quad \alpha_0 = \frac{(\mathbf{r}_0, \mathbf{r}_0)}{(\mathbf{p}_0, \mathbf{A}\mathbf{p}_0)} = \frac{3}{10},$$

$$\mathbf{x}_1 = \mathbf{x}_0 + \alpha_0 \mathbf{p}_0 = \left(\frac{3}{10}, \frac{3}{10}, \frac{3}{10} \right)^T, \quad \mathbf{r}_1 = \mathbf{r}_0 - \alpha_0 \mathbf{A}\mathbf{p}_0 = \left(\frac{1}{10}, \frac{1}{10}, \frac{1}{10} \right)^T - \left(\frac{2}{10}, \frac{9}{10}, \frac{12}{10} \right)^T$$

$$\beta_0 = \frac{(\mathbf{r}_1, \mathbf{r}_1)}{(\mathbf{r}_0, \mathbf{r}_0)} = \frac{6}{100} \times \frac{1}{3} = \frac{1}{50} \quad \mathbf{p}_1 = \mathbf{r}_1 + \beta_0 \mathbf{p}_0 = \left(\frac{31}{50}, \frac{1}{10}, \frac{2}{10} \right)^T + \left(\frac{1}{50}, \frac{1}{50}, \frac{1}{50} \right)^T$$

$$\alpha_1 = \frac{(\mathbf{r}_1, \mathbf{r}_1)}{(\mathbf{p}_1, \mathbf{A}\mathbf{p}_1)} = \frac{6}{100} \times \frac{2500}{90} = \frac{5}{3}$$

$$\mathbf{x}_2 = \mathbf{x}_1 + \alpha_1 \mathbf{p}_1 = \frac{3}{10}(1, 1, 1)^T + \frac{1}{10}(2, 2, -3)^T = \frac{1}{2}(1, 1, 0)^T$$

$$\mathbf{r}_2 = \mathbf{r}_1 - \alpha_1 \mathbf{A}\mathbf{p}_1 = \frac{1}{10}(1, 1, -2)^T - \frac{5}{3} \times \frac{3}{50}(1, 1, -2)^T = (0, 0, 0)^T$$

则方程组的解为 $\mathbf{x}_2 = (0.5, 0.5, 0)^T$ 。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

对于病态的线性方程组，CG法的收敛速度是很慢的，为了改进收敛速度，可以对方程组进行预处理，使系数矩阵的条件数降低，这种方法称**预处理共轭梯度法**（PCG法），PCG方法是目前求解病态线性方程组的有效方法之一，因此，它已成为很多计算工作者关心的方法之一，对此有兴趣的读者可以参阅文献[6]。



DUT

大连理工大学

DALIAN UNIVERSITY OF TECHNOLOGY

THE END